

Escopo de Projeto: Tradutor de Libras para Áudio com IA

Disciplina: Inteligência Artificial

Curso:

Tipo de Trabalho: Projeto Prático (Desenvolvimento de Protótipo)

1. Objetivo Principal

Desenvolver um protótipo funcional de um sistema baseado em Inteligência Artificial que utilize a câmera de um dispositivo (celular ou computador) para reconhecer, em tempo real, frases ou palavras expressas em Língua Brasileira de Sinais (Libras) e as converta em áudio (síntese de voz). O objetivo é criar uma ponte de comunicação bidirecional para pessoas com deficiência auditiva que se comunicam em Libras, permitindo que interajam com pessoas que não compreendem a língua.

2. Descrição do Problema e Relevância

Mais de 10 milhões de pessoas surdas no Brasil enfrentam barreiras diárias de comunicação. Atividades simples, como uma ligação telefônica ou um atendimento presencial, tornam-se desafios sem a presença de um intérprete. Este projeto visa propor uma solução tecnológica para reduzir essa dependência, utilizando a onipresença de smartphones e computadores para empoderar o usuário com deficiência auditiva, dando-lhe autonomia para se comunicar.

3. Escopo do Projeto e Funcionalidades

O aluno deverá entregar um protótipo que contemple as seguintes funcionalidades básicas, formando um pipeline completo de IA:

1. Captura de Vídeo: Acesso à câmera do dispositivo para capturar os gestos do usuário em tempo real.
2. Rastreamento Corporal (Feature Extraction): Utilizar uma biblioteca de visão computacional para mapear os principais pontos de referência (*landmarks*) do corpo do usuário, com foco especial nas mãos e braços. Isso converte o vídeo em dados numéricos que a IA pode processar.
3. Classificação dos Sinais (Modelo de IA): Um modelo de aprendizado de máquina (provavelmente supervisionado) deve ser capaz de interpretar os dados extraídos e classificá-los em um dos sinais de Libras para os quais foi treinado (ex: "Olá", "Água", "Preciso de ajuda").
4. Geração de Texto: A palavra ou frase classificada deve ser exibida na tela do dispositivo.
5. Síntese de Voz (Text-to-Speech): O texto gerado deve ser convertido em áudio utilizando um mecanismo de síntese de voz, que será reproduzido para o interlocutor ouvinte.

4. Tecnologias e Recursos de IA Utilizados

Para atingir o objetivo, o projeto deve se basear nas seguintes tecnologias e conceitos de IA, que são amplamente utilizados em soluções de mercado como a IA Libras e o Hand Talk .

4.1. Visão Computacional e Extração de Características

- Tecnologia Sugerida: MediaPipe (Google).
- Função: Responsável por rastrear o corpo humano. A solução ideal utiliza o MediaPipe para detectar até 190+ pontos de referência (landmarks) nas mãos, braços, rosto e corpo. Esses pontos são coordenadas numéricas (x, y, z) que descrevem a posição e o movimento, abstraindo a necessidade de processar a imagem bruta .
- Vantagem: Processamento ocorre localmente no dispositivo (*client-side*), garantindo mais privacidade e velocidade.

4.2. Modelo de Aprendizagem de Máquina (Classificação)

- Abordagem: Aprendizado Supervisionado.
- Funcionamento: O modelo será treinado com um dataset contendo sequências de landmarks (entrada) rotuladas com o nome do sinal correspondente em Libras (saída).
- Tecnologia Sugerida: TensorFlow ou PyTorch. Redes neurais profundas, como LSTM (Long Short-Term Memory) ou GRU (Gated Recurrent Units), são particularmente eficazes para interpretar sequências de movimentos ao longo do tempo .
- Métrica de Desempenho: A acurácia do modelo será medida pela porcentagem de vezes que o sinal classificado corresponde ao sinal real executado no conjunto de testes.

4.3. Síntese de Voz

- Tecnologia Sugerida: APIs de Text-to-Speech, como a Azure Speech (Microsoft) ou a biblioteca de TTS do próprio sistema operacional .
- Função: Converter o texto resultante da classificação em áudio natural.

4.4. Infraestrutura (Edge Computing vs. Cloud)

- Arquitetura Recomendada: Processamento Local (Edge).
- Motivo: Para garantir uma conversa fluida, o tempo de resposta deve ser mínimo (menos de 50ms). Depend exclusivamente da nuvem pode gerar atrasos (latência) ou falhar por instabilidade de internet. O ideal é que a etapa de reconhecimento dos gestos ocorra localmente .

5. Etapas de Desenvolvimento (Cronograma Sugerido)

Etapa	Descrição	Tecnologias Envolvidas
1. Aquisição de Dados	Criar ou obter um dataset de vídeos de pessoas sinalizando um conjunto pré-definido de palavras em Libras.	Câmera, ferramentas de rotulagem.
2. Pré-processamento	Processar os vídeos com o MediaPipe para extrair os landmarks e salvá-los como arquivos de sequência numérica (ex: CSV ou TFRecord).	Python, MediaPipe, Pandas .
3. Treinamento do Modelo	Construir e treinar uma rede neural (ex: LSTM) com os dados de landmarks para que ela aprenda a associar os movimentos às palavras.	TensorFlow/PyTorch, Scikit-learn .
4. Avaliação e Ajuste	Testar o modelo com novos dados para calcular a acurácia e outras métricas (precisão, recall). Ajustar hiperparâmetros para melhorar o desempenho.	Scikit-learn, Matplotlib.
5. Desenvolvimento da Interface	Criar uma interface simples (web ou aplicativo) que acesse a câmera, execute o modelo em tempo real e mostre/ fale o resultado.	JavaScript/HTML5 (para web), React Native/Flutter (para app).
6. Integração da Voz	Adicionar a funcionalidade de síntese de voz para reproduzir o texto traduzido.	Web Speech API, Azure TTS, etc. .

6. Resultados Esperados e Métricas de Sucesso

Ao final do projeto, o aluno deverá apresentar um relatório contendo:

1. Objetivo Principal: Conforme descrito na seção 1.
2. Tecnologias Utilizadas: Detalhamento das bibliotecas, frameworks e modelos empregados, justificando as escolhas com base na pesquisa realizada (ex: "Optamos pelo MediaPipe por sua eficiência em tempo real...").
3. Recursos de IA e Funcionamento: Explicação didática de como o pipeline de IA funciona (entrada -> extração de features -> classificação -> saída), incluindo diagramas de blocos.

4. Acurácia Alcançada:

- Cálculo: Apresentar a acurácia final do modelo de classificação no conjunto de testes. Ex: "O modelo atingiu uma acurácia de 92% no reconhecimento de 10 sinais estáticos/dinâmicos."
- Análise: Discutir os resultados. Se a acurácia foi baixa, quais as hipóteses? (Poucos dados de treinamento, variação de iluminação, sinais muito parecidos?). Conforme a literatura, sistemas maduros podem alcançar precisão superior a 97% .

5. Análise Crítica e Trabalhos Futuros:

- Quais foram as principais dificuldades?
- O modelo funciona para diferentes pessoas e condições de iluminação?
- Como o projeto poderia ser escalado para reconhecer frases completas ou um vocabulário maior? (Ex: utilizando modelos de linguagem e aprendizado contínuo) .

7. Referências para Consulta

- IA Libras: <https://ialibras.com.br/> - Para entender a arquitetura de ponta a ponta .
- Hand Talk: Pesquisar sobre o uso de ISLR (Isolated Sign Language Recognition) .
- Lenovo & CESAR: Leitura sobre os desafios de dados e a importância da computação de borda (*edge computing*) .
- MediaPipe: Documentação oficial para detecção de mãos e poses.